

Entropy and Cross Entropy and KL divergence

熵 Entropy

我们用熵 (Entropy) 来描述一个系统或一个事件的不确定性。“熵”这一概念本身来自于热力学，香农的信息熵是本文的主要讨论内容。

回顾一下概率论，考虑一个随机试验 E ，举例为“抛掷一颗骰子，观察出现的点数”；随机试验 E 所有可能出现的基本事件（基本事件：结果单一不可再分解，每一个基本事件彼此不相容）组成的集合，称为样本空间 S ，对于本例就是， $S = \{1\text{点朝上}, 2\text{点朝上}, \dots\}$ ；考虑事件域 \mathcal{F} 中的一个元素/事件“骰子点数为偶数”，即 $A = \{\text{骰子点数为偶数}\}$ ，用随机变量 X 表示（随机变量），则 $X = \{2, 4, 6\}$ ；（随机变量是一个实值函数，将一个事件映射为一个值）

<https://www.zhihu.com/question/20642770>

（后续另辟一章笔记：概率论三要素）

考虑一事件 A ，其对应离散随机变量 X 的取值范围为 $\{x_1, x_2, \dots, x_N\}$ ，则离散随机变量 X 的信息熵定义如下：

$$H(X) = - \sum_{i=1}^N p(x_i) \cdot \log p(x_i) \quad (1)$$

其中 $p(\cdot)$ 表示其中基本事件发生的概率。

无损编码长度的最小长度

交叉熵 Cross Entropy

考虑两个概率分布 p, q 交叉熵定义如下：

$$H(p, q) = - \sum_x p(x) \log q(x) \quad (2)$$

表示用 q 去编码 p 的冗余编码长度


假定标签分布/真实分布为 y_i ，网络/模型输出 logits 经过 softmax 处理后分布为 $p(x_i)$ ，则交叉熵计算如下，

$$\mathcal{L} = H(y, p) = - \sum_{i=1}^N y_i \log p(x_i) \quad (3)$$

其中 softmax 处理操作如下，

$$p(x_i) = \frac{\exp(z_i)}{\sum_{j=1}^N \exp(z_j)} \quad (4)$$


做 gradient flow 图如下，



接下来我们考虑交叉熵损失函数对 $logits$ 的导数:

$$\frac{\partial \mathcal{L}}{\partial z_i} = \sum_{j=1}^N \left(\frac{\partial \mathcal{L}}{\partial p_j} \cdot \frac{\partial p_j}{\partial z_i} \right) \quad (5)$$

求和中的子项即计算图中的一条“路径”:



由于 $softmax$ 操作, 所有 p_j 都是 z_i 的函数, 所以需要求和操作; 但由于 $softmax$ 操作, i, j 不同/相同的情况下 p_j 对 z_i 的偏导不一致, 当 $i \neq j$ 时有:

$$\frac{\partial \mathcal{L}}{\partial p_j} \cdot \frac{\partial p_j}{\partial z_i} \Big|_{i \neq j} = \frac{\partial}{\partial p_j} \left[-\sum_{k=1}^N y_k \log p_k \right] \cdot \frac{\partial p_j}{\partial z_i} \quad (6)$$

$$= -\frac{y_j}{p_j} \cdot \frac{\partial p_j}{\partial z_i} \quad (7)$$

$$= -\frac{y_j}{p_j} \cdot \frac{\partial}{\partial z_i} \left[\frac{\exp(z_j)}{\sum_{k=1}^N \exp(z_k)} \right] \quad (8)$$

$$= -\frac{y_j}{p_j} \cdot \frac{\partial}{\partial z_i} \left[\frac{\exp(z_j)}{\sum_{k \neq i}^N \exp(z_k) + \exp(z_i)} \right] \quad (9)$$

$$= -\frac{y_j}{p_j} \cdot \left[\frac{-\exp(z_i) \cdot \exp(z_j)}{[\sum_{k=1}^N \exp(z_k)]^2} \right] \quad (10)$$

$$= -\frac{y_j}{p_j} \cdot \left[-\frac{\exp(z_i)}{\sum_{k=1}^N \exp(z_k)} \cdot \frac{\exp(z_j)}{\sum_{k=1}^N \exp(z_k)} \right] \quad (11)$$

$$= -\frac{y_j}{p_j} \cdot -p_i \cdot p_j \quad (12)$$

$$= y_j \cdot p_i \quad (13)$$

同理，当 $j = i$ 时，求导如下：

$$\frac{\partial \mathcal{L}}{\partial p_j} \cdot \frac{\partial p_j}{\partial z_i} \Big|_{i=j} = \frac{\partial}{\partial p_i} \left[-\sum_{k=1}^N y_i \log p_k \right] \cdot \frac{\partial p_i}{\partial z_i} \quad (14)$$

$$= -\frac{y_i}{p_i} \cdot \frac{\partial p_i}{\partial z_i} \quad (15)$$

$$= -\frac{y_i}{p_i} \cdot \frac{\partial}{\partial z_i} \left[\frac{\exp(z_i)}{\sum_{k=1}^N \exp(z_k)} \right] \quad (16)$$

$$= -\frac{y_i}{p_i} \cdot \frac{\partial}{\partial z_i} \left[\frac{\exp(z_i)}{\sum_{k \neq i}^N \exp(z_k) + \exp(z_i)} \right] \quad (17)$$

$$= -\frac{y_i}{p_i} \cdot \left[\frac{\exp(z_i) \cdot \sum_{k=1}^N \exp(z_k) - \exp(z_i) \cdot \exp(z_i)}{[\sum_{k=1}^N \exp(z_k)]^2} \right] \quad (18)$$

$$= -\frac{y_i}{p_i} \cdot \left[\frac{\exp(z_i)}{\sum_{k=1}^N \exp(z_k)} \cdot \frac{(\sum_{k=1}^N \exp(z_k)) - \exp(z_i)}{\sum_{k=1}^N \exp(z_k)} \right] \quad (19)$$

$$= -\frac{y_i}{p_i} \cdot \left[\frac{\exp(z_i)}{\sum_{k=1}^N \exp(z_k)} \cdot \left(1 - \frac{\exp(z_i)}{\sum_{k=1}^N \exp(z_k)} \right) \right] \quad (20)$$

$$= -\frac{y_i}{p_i} \cdot p_i \cdot (1 - p_i) \quad (21)$$

$$= y_i \cdot (p_i - 1) \quad (22)$$

考虑公式(5)，则求导改写为：

$$\frac{\partial \mathcal{L}}{\partial p_j} \cdot \frac{\partial p_j}{\partial z_i} = \sum_{j \neq i}^N y_j \cdot p_i + y_i \cdot (p_i - 1) \quad (23)$$

$$= p_i \sum_{j \neq i}^N y_j + (p_i \cdot y_i - y_i) \quad (24)$$

$$= p_i \sum_j^N y_j - y_i \quad (25)$$

$$= p_i - y_i \quad (26)$$

那为什么label smooth能work？（从求导角度的一种解释）

label smooth 区别于传统 one-hot的label:

$$y_i = \begin{cases} 1 - \epsilon, & \text{i is true label} \\ \frac{\epsilon}{K-1}, & \text{otherwise} \end{cases} \quad (27)$$

由于 $p_i = \frac{\exp(z_i)}{\sum_j \exp(z_j)}$, 对于one-hot的label来说要求 $\exp(z_i) = \sum_{j \neq i} \exp(z_j) + \exp(z_i)$, 也就是要求 $\sum_{j \neq i} \exp(z_j) = 0$ 要求所有不是label对应维度的logits趋近于负无穷, 而对于label smooth来说要求 $\exp(z_i) = (1 - \epsilon) \left[\sum_{j \neq i} \exp(z_j) + \exp(z_i) \right]$, 移项化简有: $\exp(z_i) = \frac{(1-\epsilon)}{\epsilon} \cdot \sum_{j \neq i} \exp(z_j)$; 有助于优化 (待续)

KL散度 Kullback-Leibler Divergence